





20.11.2015, Marcel Becker

© Copyright 2013 anderScore GmbH

Schedule



1. Was ist Solr? 2. Grundlagen Suchen 3. Schema 4. Solr Features / Solr Cloud 5. Hands On 6. Fragen 7. Links

Über mich





- Software Entwickler (Dipl.-Inf.) bei der anderScore GmbH, Köln
- Einige Jahre Erfahrung im Umfeld
 - Java
 - Web
 - Agile Methoden

Suche / Suchmaschine





Suche / Suchmaschine



- Wenig Struktur
- Natürliche Sprache
- Viele Treffer
- Große Datenmengen

Apache Lucene



High Performance

Index & Search



Apache Software License

Java Bibliothek

Apache Solr



Stand-alone Server

HTTP / XML / JSON / CSV



Apache Software License

Cluster / Cloud

Grundlagen



Grundlagen

Invertierter Index



Dokumente

- Dokument 1: Die Hauptstadt von Frankreich heißt Paris.
- Dokument 2: Paris ist die Hauptstadt von Frankreich.
- Dokument 3: Die Hauptstädte von England bzw. Frankreich heißen London bzw. Paris.

Invertierter Index:


- bzw. -> 3
- die -> 1, 2, 3
- England -> 3
- Frankreich -> 1, 2, 3
- Hauptstadt -> 1, 2
- Hauptstädte -> 3

- heißen -> 3
- heißt -> 1, 2
- ist -> 2
- London -> 3
- Paris -> 1, 2, 3
- von -> 1, 2, 3

Quelle: http://wikis.gm.fh-koeln.de/wiki_ir/InformationRetrieval/Invertierte-Liste


Indexer Pipe





Query Pipe






Beispiel






Dokument: Die Froscon findet in der Hochschule Bonn-Rhein-Sieg statt.



Tokens: froscon, findet, hochschule, fh, bonnrhein-sieg, brs, statt



Query: FH BRS FrosCon 2015



Tokens: fh, brs, froscon, 2015



Match: fh, brs, froscon

Ranking / Score



- tf Term Frequency
- idf Inverse Document Frequency
- coord Coordination Factor
- fieldNorm Field length
- distance bei Fuzzy Search
- boost
 - Index
 - Query: title:"foo bar"^10

schema.xml



```
<fieldType name="text general" class="solr.TextField">
  <analyzer type="index">
     <charFilter class="solr.MappingCharFilterFactory" mapping="ascii.txt"/>
     <tokenizer class="solr.WhitespaceTokenizerFactory" />
     <filter class="solr.LowerCaseFilterFactory" />
     <filter class="solr.StopFilterFactory" words="stopwords.txt" />
     <filter class="solr.SynonymFilterFactory" synonyms="synonyms.txt" />
  </analyzer>
  <analyzer type="query">
     <charFilter class="solr.MappingCharFilterFactory" mapping="ascii.txt"/>
     <tokenizer class="solr.WhitespaceTokenizerFactory" />
     <filter class="solr.LowerCaseFilterFactory" />
     <filter class="solr.StopFilterFactory" words="stopwords.txt" />
  </analyzer>
</fieldType>
<field name="text" type="text general" indexed="true" stored="true" />
<dynamicField name="* txt" type="text general" indexed="true" stored="true" />
```




Java API

```
String collection = "anderscore";
Book book = new Book();
book.id = "1";
book.author txt = "Eric Ries";
book.title txt = "The Lean Startup";
Address address = new Address();
address.id = "2":
address.addressLine txt = "Grantham-Allee 20";
address.postalCode txt = "53757";
address.city txt = "Sankt Augustin";
address.country txt = "Germany";
CloudSolrClient c = new CloudSolrClient("localhost:2001");
c.addBean(collection, book);
c.addBean(collection, address);
c.close();
```




Admin UI






Geospatial Support




Quelle: Google Maps



Facets:







Quelle: http://lucene.apache.org/solr/features.html

SolrCloud



- Menge von Features, die helfen einen Index horizontal zu skalieren (verteilen):
 - Sharding
 - Replikation
- Ziele:
 - Skalierbarkeit
 - Performance
 - Hoch-Verfügbarkeit
 - Einfachheit / Komfort

SolrCloud - Terminologie



- ZooKeeper
 - Zentralisierte Konfiguration
 - Cluster-State Management
 - Leader Election
- Node
- Core
- Collection
 - Shard
 - Replication Factor
 - Hash Range
 - Leader
- Replica
- Leader

Quelle: http://de.slideshare.net/thelabdude/solr-exchange-introtosolrcloud

Solr Hands On



Hands On

Fragen







Danke

Quellen und Links



- http://lucene.apache.org/solr/
- http://lucene.apache.org/index.html
- http://wikis.gm.fhkoeln.de/wiki_ir/InformationRetrieval/Invertierte-Liste
- http://de.slideshare.net/thelabdude/solr-exchangeintrotosolrcloud

Anhang




Anhang

Solr Indexes




Classic Solr



Distributed Indexes



Solr Cloud (Logical View)



Distributed Indexes



Solr Cloud (Physical View)

